

BÖLÜM 19 / CHAPTER 19

ZATÜRRE HASTALIĞININ TEŞHİSİNE YÖNELİK FARKLI YAPAY ZEKÂ MODELLERİNİN KARŞILAŞTIRILMASI

COMPARISON OF DIFFERENT ARTIFICIAL INTELLIGENCE MODELS FOR THE DETECTION OF PNEUMONIA

Mustafa Furkan AKSU*, Muhammed Çağrı AKSU, Ersin KARAMAN*****

*Arş. Gör., İzmir Bakırçay Üniversitesi, Mühendislik ve Mimarlık Fakültesi, Elektrik-Elektronik Mühendisliği,
İzmir, Türkiye

E-posta: aksu.mustafafurkan@gmail.com

**Dr. Öğr. Üyesi, Artvin Çoruh Üniversitesi, Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü,
Artvin Türkiye

E-posta: cagriaksu@artvin.edu.tr

***Prof. Dr., Ankara Hacı Bayram Veli Üniversitesi, Sanat ve Tasarım Fakültesi, Görsel Sanatlar Bölümü,
Ankara, Türkiye

E-posta: ersin.karaman@hbm.edu.tr

DOI: 10.26650/B/ET07.2023.005.19

ÖZ

Oldukça ölümcül bir hastalık olan zatürrenin doğru bir şekilde teşhis edilmesi hayati önem taşımaktadır. Uzman gerekliliğini azaltması, hastalığın teşhisinin daha hızlı ve kolay yapılabilmesini sağlaması nedeniyle son yıllarda zatürre hastalığının yapay zekâ yöntemleriyle teşhis edilmesine yönelik çokça çalışma yapılmaktadır. Yapay zekâ yöntemleriyle gerçekleştirilen zatürre teşhisi genellikle hastalık barındıran ve barındırmayan akciğer röntgen görüntülerinin yapay zekâ modeline öğretilmesi ve eğitilmiş modelin belirli bir doğruluk derecesinde hastalık teşhisine yönelik tahmin yapmasıyla gerçekleştirilmektedir. Yapay zekâ yöntemiyle gerçekleştirilen teşhis işlemi aslında bir tahmin işlemi olduğu için teşhis, belirli bir doğruluk derecesinde yapılabilir. Dolayısıyla zatürre teşhisine yönelik gerçekleştirilen farklı yapay zekâ modellerinin karşılaştırılması ve doğruluğu daha yüksek olan modellerin tespit edilmesi önem arz etmektedir. Bu nedenle bu çalışmada, zatürre hastalığının teşhisinin, yapay zekâ yöntemleri ile daha doğru ve daha hızlı yapılmasına katkı sağlamak amacıyla çeşitli yapay zekâ modelleri oluşturulmuş ve bu modellerin zatürre teşhisine yönelik tahmin doğrulukları karşılaştırılmıştır. Yapay zekâ modelleri oluşturmak için Kermany, Zhang ve Goldbaum (2018) tarafından oluşturulan “Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images

for Classification” isimli veri setindeki göğüs röntgeni görüntüleri kullanılmıştır. Veri setinde 5856 röntgen görüntüsü bulunmaktadır. Bu görüntülerin 4273’ü zatürre hastalığına sahip insanlara, 1583’ü ise hastaliksız insanlara aittir. Veri setinin sınıfları arasındaki bu dengesizlik yapay zekâ modellerinin belirli bir sınıfa aşırı öğrenmesine neden olmaktadır. Bu nedenle her sınıftan eşit sayıda örnek alınarak toplamda 3160 röntgen görüntüsü ile çalışma gerçekleştirilmiştir. Çalışma için oluşturulan yapay zekâ modelleri, ResNet152V2, VGG16, VGG19, DenseNet201 ve Xception evrimsel sinir ağlarının bu çalışmaya uygun olarak aynı koşullar altında transfer öğrenme tekniğiyle yeniden eğitilmeleriyle oluşturulmuştur. Oluşturulan yapay zekâ modellerinin doğruluk, f1-skoru, kesinlik ve kayıp performans metrikleri elde edilmiş ve bu metrikler kullanılarak modeller karşılaştırılmıştır. Karşılaştırma neticesinde en başarılı sınıflandırma sonucuna %96’lık doğruluk değeriyle DenseNet201 ağıyla oluşturulan yapay zekâ modeliyle ulaşılmıştır. Sonuç olarak, zatürre hastalığının teşhisine yönelik farklı yapay zekâ modellerinin karşılaştırıldığı bu deneysel çalışma neticesinde oluşturulan yapay zekâ modellerinin, uzman hekimlerce yapılan zatürre teşhislerinde karar desteği sağlaması ve elde edilen sonuçların ilgili literatüre katkı sunması beklenmektedir.

Anahtar Kelimeler: Zatürre, akciğer röntgeni, derin öğrenme, yapay zekâ, evrimsel sinir ağları, öğrenme aktarımı, DenseNet201, ResNet152V2, VGG19, VGG16, Xception

ABSTRACT

Accurate diagnosis of pneumonia, which is a very deadly disease, is vital. In recent years, a lot of work has been done on the diagnosis of pneumonia with artificial intelligence methods, since it reduces the need for specialists and enables the diagnosis of the disease to be made faster and easier. Pneumonia diagnosis made by artificial intelligence methods is usually performed by teaching the disease-free and non disease-free lung x-ray images to the artificial intelligence model and the trained model making a prediction for the diagnosis of the disease with a certain degree of accuracy. The diagnosis can be made with a certain degree of accuracy, since the diagnosis process performed with the artificial intelligence method is actually an estimation process. Therefore, it is important to compare different artificial intelligence models for the diagnosis of pneumonia and to determine models that have higher accuracy. For this reason, in this study, various artificial intelligence models were created in order to contribute to the diagnosis of pneumonia disease with artificial intelligence methods more accurately and faster, and the estimation accuracy of these models for the diagnosis of pneumonia was compared. To create artificial intelligence models, chest X-ray images in the dataset named “Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images for Classification” created by Kermany, Zhang and Goldbaum (2018) were used. There are 5856 x-ray images in the data set. Of these images, 4273 are of people with pneumonia, and 1583 are of people without the disease. This imbalance between the classes of the data set causes artificial intelligence models to over-learn a particular class. For this reason, study was carry out with an equal number of samples were taken from each class a total of 3160 x-ray images. The artificial intelligence models created for the study were created by retraining the ResNet152V2, VGG16, VGG19, DenseNet201 and Xception convolutional neural networks under the same conditions with the transfer learning technique, in accordance with this study. Accuracy, f1-score, precision and loss performance metrics of the created artificial intelligence models were obtained and the models were compared using these metrics. As a result of the comparison, the most successful classification result was achieved with the artificial intelligence model created with the DenseNet201 network with an accuracy value of 96%. As a result, it is expected that the artificial intelligence models created as a result of this experimental study, in which different artificial intelligence models for the diagnosis of pneumonia are compared, will provide decision support in the diagnosis of pneumonia made by specialist physicians and the results obtained will contribute to the relevant literature.

Keywords: Pneumonia, chest x-ray, deep learning, artificial intelligence, convolutional neural networks, transfer learning, DenseNet201, ResNet152V2, VGG19, VGG16, Xception

1. Giriş

Zatürre genellikle virüs ya da bakterilerin sebep olduğu bir akciğer hastalığıdır. Hastalık genellikle doğrudan temas ile çevreden bulaşabilmektedir. Zatürre hastaları; öksürük, ateş, nefes almakta zorluk ve halsizlik gibi belirtiler göstermektedir (Jones vd., 2016). Oldukça ölümcül bir hastalık olan zatürrenin doğru bir şekilde teşhis edilmesi hayati önem taşımaktadır.

Zatürre hastalığının teşhisi için akciğeri dinleme, kan testi, göğüs röntgeni gibi tanı yöntemleri kullanılmaktadır. Zatürre teşhisi için mevcut olan en iyi yöntem göğüs röntgen görüntülerinin uzman doktorlar tarafından incelenmesidir (World Health Organization Pneumonia Vaccine Trial Investigators' Group, 2001). Fakat bu yöntemle bile uzman doktorlar, zatürre teşhisi koymakta zorlanabilmektedirler (Jones vd., 2016; World Health Organization Pneumonia Vaccine Trial Investigators' Group, 2001). Ayrıca yeterli uzman doktorun bulunmadığı ve zaman kısıtlılığının olduğu durumlarda teşhis işlemi daha da zorlaşmaktadır. Bu gibi durumlarda hastalık teşhisinin yapay zekâ yöntemleriyle gerçekleştirilmesi hayat kurtarıcı rol oynayabilmektedir. Ancak yapay zekâ yöntemleriyle oluşturulan hastalık teşhisi modelleri belirli bir doğruluk oranında çalışmaktadır. Dolayısıyla zatürre hastalığının teşhisine yönelik oluşturulan yapay zekâ modellerinin karşılaştırılıp en iyi performansı sunan modelin tespit edilmesi önem arz etmektedir. Bu nedenle bu çalışmada, zatürre hastalığının teşhisinin, yapay zekâ yöntemleri ile daha doğru ve daha hızlı yapılmasına katkı sağlamak amacıyla çeşitli yapay zekâ modelleri oluşturulmuş ve bu modellerin zatürre teşhisine yönelik tahmin doğrulukları karşılaştırılmıştır.

Literatürde zatürre hastalığının yapay zekâ yöntemleriyle tespitine ilişkin çeşitli çalışmalar bulunmakta olup; bu çalışmaların ortak noktaları zatürre hastalığının tespitine yönelik yapay zekâ yöntemi olarak evrimsel sinir ağlarının kullanılmasıdır (Rajpurkar vd., 2017; Wang vd., 2017). Evrimsel sinir ağlarını oluşturmak oldukça zaman almakta ve büyük veri setleri gerektirmektedir (Elshaer vd., 2019). Literatürdeki çalışmaların diğer bir ortak noktası ise önceden eğitilmiş ağların ve öğrenme aktarımı tekniğinin kullanılmasıdır (Milante vd., 2020; Rajpurkar vd., 2017; Wang vd., 2017). Bu nedenle bu çalışmada önceden eğitilmiş ağların zatürre hastalığının tespitine yönelik başarıları karşılaştırılmıştır. Ağ olarak ResNet152V2, VGG16, VGG19, DenseNet201 ve Xception ağları kullanılmıştır. Bu ağlar bu çalışmaya uygun olarak aynı koşullar altında transfer öğrenme tekniğiyle yeniden eğitilmeleriyle oluşturulmuştur ve zatürre teşhisine yönelik performansları karşılaştırılmıştır.


Çalışma toplamda beş bölümden oluşmakta olup; ikinci bölümde çalışmada değinilen kavramlar kısaca açıklanmıştır. Üçüncü bölümde çalışmada kullanılan veri seti ve çalışmanın

yöntemi açıklanmıştır. Dördüncü bölümde gerçekleştirilen deneyler neticesinde elde edilen bulgular verilmiştir. Beşinci ve son bölümde ise ulaşılan sonuçlar verilmiştir.

2. Kavramlar

2.1. Evrişimsel Sinir Ağları

Yapay zekâ, insan gibi düşünebilen ve bu şekilde çeşitli sorunları çözebilen makineler oluşturmayı amaçlamaktadır (Yılmaz, 2020). Makine öğrenmesi ise bilgisayarların insanlar gibi öğrenebilmesini sağlayan bir hesaplama algoritmasıdır ve yapay zekânın alt dalıdır (Bi vd., 2019). Makine öğrenmesinin de bir alt dalı olan derin öğrenme, verilerden çeşitli özelliklerin çıkarılmasını sağlamaktadır. Derin öğrenmenin ayırt edici özelliği, sahip olduğu çok katmanlı yapısıdır. Evrişimsel Sinir Ağları (ESA) derin öğrenmede kullanılan popüler metotlardan biridir (Dandıl vd., 2019). ESA'nın görüntü verileri üzerindeki başarısı yaygın olarak kabul edilmektedir (Krizhevsky vd., 2017). ESA algoritması Şekil 1'de görüldüğü gibi iki temel yapı taşından oluşmaktadır (Ng vd., t.y.). Bunlardan ilki öznitelik çıkarımıdır. Öznitelik çıkarımı kısmında giriş görüntüsüne çeşitli konvolüsyon işlemleri uygulanmaktadır. Bu işlemler neticesinde, görüntülerden önemli öznitelikler elde edilmekte ve bu öznitelikler bir matriste toplanmaktadır. Bu kısımda yapılan bir diğer işlem ise havuzlamadır. Havuzlama, temel olarak bir boyut küçültme işlemidir. Havuzlama işlemi ortalama değer ve maksimum değer olmak üzere iki şekilde gerçekleşmektedir. Ortalama değer işleminde filtrenin denk geldiği kısımların ortalaması alınırken, maksimum değer işleminde filtrenin denk geldiği kısımdaki maksimum piksel değeri alınmaktadır (Arı ve Hanbay, 2019). İkinci kısım ise sınıflandırma kısmıdır. Bu kısımda ise öznitelik çıkarımından elde edilen matris düzleştirilmekte ve bir dizi haline getirilmektedir. Bu işlem "Flatten" olarak adlandırılmaktadır. Elde edilen dizi bir yapay sinir ağına gönderilmekte ve sınıflandırma gerçekleştirilmektedir.



Şekil 1: ESA algoritmasına ait şema (Ergin, 2018)

2.2. Öğrenme Aktarımı

Bir problem için eğitilmiş ağların başka bir problem için kullanılmasına öğrenme aktarımı denilmektedir (Elshaer vd., 2019). Öğrenme aktarımı tekniği için önceden eğitilmiş çeşitli evrişimsel sinir ağları mevcuttur. Bu ağlar daha önceden büyük veri setleri ile eğitildiği için içlerinde birçok bilgiyi barındırmaktadırlar. Bu nedenle bu ağların çeşitli problemlerde kullanılması yüksek başarı, hızlı eğitim süreleri, küçük veri setleri ile eğitim yapabilme gibi avantajlar sağlamaktadır (Yang vd., 2020).

Bu çalışmada önceden eğitilmiş; VGG-16, VGG-19, DenseNet201, ResNet152V2, Xception evrişimsel sinir ağları öğrenme aktarımı için kullanılmıştır. Kullanılan modellere ait özellikler tablosu Tablo 1’de verilmiştir. Tabloda modellere ait hesaplayabildikleri parametre sayısı ve ilgili modellerden elde edilen en iyi 5 doğruluk değerleri verilmiştir. Derinlik kısmında ise modellerin katman sayıları gösterilmiştir.

Tablo 1. Kullanılan Modellerin Özellikleri			
Model	En İyi 5 Doğruluk	Parametre Sayısı	Derinlik
Xception	0.945	22,910,480	81
VGG-16	0.901	138,357,544	16
VGG-19	0.900	143,667,240	19
DenseNet201	0.936	20,242,984	201
ResNet152V2	0.942	60,380,648	307

Çalışmada kullanılan evrişimsel sinir ağı modelleri aşağıda kısaca açıklanmıştır.

2.2.1. DenseNet201

Bu model 201 katman derinliğine sahiptir. Klasik evrişimsel sinir ağı modellerinde katmanlar birbirlerine sırayla bağlıdır ve bir katmanın çıkışı diğerinin girişine verilir. Fakat DenseNet mimarisinde önceki tüm katmanların çıkışları, herhangi bir katman için giriş olarak verilebilir. Bu da model performansını iyileştirmektedir. Model, 20 milyon parametreye sahiptir ve giriş görüntü boyutu 224x224 pikseldir. Modelin DenseNet121, DenseNet169, DenseNet201, DenseNet264 gibi farklı versiyonları bulunmaktadır (Ergün ve Kılıç, 2021).

2.2.2. ResNet152V2

307 katman derinliğine sahip bir evrişimsel sinir ağı modelidir. 2014 yılında düzenlenen ILSVRC-2014 etkinliğindeki popüler modellerden biridir. Ayrıca ILSVRC-2015 etkinliğinde

birinci olmuştur. ImageNet veri seti ile eğitilmiştir. 60,3 milyon parametreden oluşmaktadır. ResNet mimarisinin ResNet50, ResNet101, ResNet152, ResNet50V2, Resnet101V2 gibi versiyonları bulunmaktadır (JingpengZhai vd., 2020).

2.2.3. VGG16

Oxford Üniversitesi tarafından ILSVRC-2014 etkinliğine gönderilen popüler modellerden biridir. ImageNet veri seti kullanılarak eğitilmiş ve %92.7 başarıya ulaşmıştır. 16 katman derinliğine sahip bir modeldir. 138 milyonun üzerinde parametre içermektedir (Hassan, 2018).

2.2.4. VGG19

Oxford Üniversitesi tarafından yayınlanmış 19 katman derinliğine sahip modeldir. ImageNet veriseti ile eğitilmiştir. 143 milyonun üzerinde parametreye sahiptir. VGG ağlarında küçük boyutlu filtreler kullanılarak performans artışı elde etmek amaçlanmıştır (Ergün ve Kılıç, 2021; Kaushik, 2019).

2.2.5. Xception

Google tarafından 2017 yılında sunulmuştur. Google tarafından oluşturulan bir model olan Inception’ün ileri versiyonu olarak nitelenmektedir. 81 adet katman içermektedir. Yaklaşık 23 milyon parametreye sahip olmasına rağmen daha yüksek performans sağlamaktadır (Chollet, 2017).

3. Materyal ve Metot


3.1. Veri Seti

Bu çalışmada x-ray görüntülerini kullanarak zatürre hastalığının teşhisini yapan farklı yapay zekâ modelleri karşılaştırılmıştır. Bunun için de Kermany, Zhang ve Goldbaum (2018) tarafından oluşturulan göğüs röntgen görüntülerinden oluşan veri seti kullanılmıştır (Mooney, 2017). Veri setinde ‘normal’ ve ‘zatürre’ olmak üzere iki sınıf bulunmaktadır. ‘normal’ sınıfında 1583, ‘zatürre’ sınıfında 4273 adet röntgen görüntüsü bulunmaktadır. Veri seti sınıf sayılarından anlaşıldığı üzere oldukça dengesizdir. Veri setindeki sınıflar arasındaki dengesizlik, oluşturulacak yapay zekâ modelinin belirli bir sınıfı aşırı öğrenmesine sebebiyet vermektedir. Bunu engellemek ve veri setini dengeli hale getirmek adına her sınıftan 1580 adet olmak üzere toplamda 3160 görüntü rastgele seçilmiştir. Verilerin %70’i eğitim, %20’si test, %10’u doğrulama için kullanılmıştır.

3.2. Metot

Derin öğrenme metotlarından olan evrişimsel sinir ağlarının görüntü verileri üzerinde oldukça başarılı olduğu kabul edilmektedir (Krizhevsky vd., 2017). Bu çalışmada kullanılan veri seti de görüntü verilerinden oluştuğundan çalışmada evrişimsel sinir ağları kullanılmıştır. Kullanılan veri seti ile daha yüksek performans alabilmek ve hızlı eğitim yapabilmek için önceden eğitilmiş modeller kullanılarak öğrenim aktarımı yapılmıştır.

Çalışmada birden fazla evrişimsel sinir ağı kullanıldığı için bu ağların çıkış katmanları probleme uygun hale getirilmiştir. Bunun için her ağın çıkış katmanları özelleştirilmiştir. Kullanılan modellerin sonlarına havuzlama katmanı, tam bağlı katman ve sınıflandırma katmanı eklenmiştir. Tam bağlı katman aktivasyon fonksiyonu olarak “relu” kullanılırken, sınıflandırma aktivasyon fonksiyonu olarak “sigmoid” kullanılmıştır. Eğitimler 200 iterasyonda gerçekleştirilmiştir. Modellerin kullanımına ait şema Şekil 2’de verilmiştir.



Şekil 2: Kullanılan Modellerin Mimarisi

4. DeneySEL Sonuçlar


Bu çalışmada VGG-16, VGG-19, DenseNet201, ResNet152V2, Xception evrişimsel sinir ağlarıyla oluşturulan modeller belirtilen veri seti ile eğitilmiştir. Eğitimler, tarayıcı üzerinden

güçlü bilgisayarların kullanımına olanak sağlayan Google Colab kullanılarak gerçekleştirilmiş. Eğitim yazılımı Python programlama dili ve ilgili kütüphaneler kullanılarak yazılmıştır.

Seçilen farklı modeller ile eşit şartlar altında eğitilmiş ve en iyi performansı veren model elde edilmeye çalışılmıştır. Eğitim sonuçları; modellerin doğruluk değerleri neticesinde değerlendirilmiştir. Modellerin performans değerlendirmesi Tablo 2’de verilmiştir. En düşük doğruluk değeri 0.92 ile VGG16 modeliyle elde edilmiştir. En yüksek doğruluk değeri ise 0.96 ile DenseNet201 modeliyle elde edilmiştir.


Tablo 2. Modellerden Elde Edilen Performans Metrikleri				
Model	Kesinlik	Duyarlılık	F1-Skoru	Doğruluk
VGG16	0.93	0.92	0.92	0.92
Xception	0.94	0.93	0.93	0.93
VGG19	0.95	0.94	0.94	0.94
ResNet152V2	0.96	0.95	0.95	0.95
DenseNet201	0.96	0.96	0.96	0.96

En iyi sınıflandırma performansına sahip olan DenseNet201 modeline ait kayıp ve doğruluk grafiği Şekil 3’de verilmiştir. Doğruluk ve kayıp grafiğinde görüldüğü üzere doğruluk değeri 0.96’da, kayıp değeri ise 0.1’in altında sonlandığı görülmektedir.



Şekil 3: DenseNet201 Modelinin Doğruluk ve Kayıp Grafikleri

Şekil 4’de en iyi sınıflandırma performansını sağlayan DenseNet201 modeline ait hata matrisi görülmektedir. “0” ile belirtilen normal sınıfı, “1” ile belirtilen ise zatürre sınıfıdır. Matriste görüldüğü üzere model, test verisinde bulunan toplam 316 normal sınıfındaki gözse- lin tamamını doğru tahmin ederken, zatürre sınıfındaki görsellerin 291 tanesini doğru tahmin etmiştir. Modelin her sınıf için sınıflandırma performansına bakıldığında iki sınıf arasında büyük bir fark olmadığı görülmektedir.



Şekil 4: DenseNet201 Modelinin Hata Matrisi

5. Tartışma ve Sonuç

Bu çalışmada röntgen görüntüleri kullanılarak eğitilen beş farklı model ile zatürre hastalığının tespiti yapılmaya çalışılmıştır. Modeller arasında en iyi doğruluk değeri (%96) DenseNet201 modeli ile elde edilmiştir.

Yapay zekâ modellerinin oluşturulması zaman ve işlem gücü açısından oldukça maliyetlidir. Bu durum göz önüne alındığında farklı yapay zekâ modellerinin oluşturulması ve başarılarının literatüre sunulması, aynı işlemin farklı araştırmacılar tarafından tekrarlanması önüne geçmekte ve optimum çözüme ulaşma noktasında fayda sağlamaktadır. Çalışmaya bu yönden bakıldığında elde edilen sonuçların literatüre katkı sunduğu düşünülmektedir.

Çalışmada üretilen yapay zekâ modelleri bilgisayar destekli tanı sistemlerine entegre edilerek zatürre teşhisinde uzman doktora karar desteği sağlayabilir. Elde edilen sonuçlar bu yönüyle de önem arz etmektedir. Ayrıca üretilen yapay zekâ modelleri, uzman personel eksikliği olan, kısıtlı bir zaman dilimi içerisinde birçok hastaya bakılma durumu olan üçüncü dünya ülkelerinde hayat kurtarıcı rol oynayabilir.

Kaynakça / References

- Arı, A., & Hanbay, D. (2019). Tumor detection in MR images of regional convolutional neural networks. *Journal of the Faculty of Engineering and Architecture of Gazi University*, 34(3), ss.1396-1409. <https://doi.org/10.17341/gazimmfd.460535>
- Bi, Q., Goodman, K. E., Kaminsky, J., & Lessler, J. (2019). What is Machine Learning? A Primer for the Epidemiologist. *American Journal of Epidemiology*, 188(12), ss. 2222-2239. <https://doi.org/10.1093/aje/kwz189>

- Chollet, F. (2017). Xception: Deep Learning with Depthwise Separable Convolutions. Conference on Computer Vision and Pattern Recognition (CVPR), <https://doi.org/10.1109/CVPR.2017.195>
- Dandil, E., Turkan, M., Boğa, M., & Çevik, K. K. (2019). Daha Hızlı Bölgesel-Evrişimsel Sinir Ağları ile Sığır Yüzlerinin Tanınması. Bilecik Şeyh Edebalı Üniversitesi Fen Bilimleri Dergisi, 6, 177-189. <https://doi.org/10.35193/bseufbd.592099>
- Elshaer, M., Wisdom, S., & Mishra, T. (2019). Transfer Learning From Sound Representations For Anger Detection in Speech. ArXiv, abs/1902.02120.
- Ergin, T. (2018). Convolutional Neural Network (ConvNet yada CNN) nedir, nasıl çalışır? Medium. <https://medium.com/@tuncerergin/convolutional-neural-network-convnet-yada-cnn-nedir-nasil-calisir-97a0f5d34cad>
- Ergün, E., & Kılıç, K. (2021). Derin Öğrenme ile Artırılmış Görüntü Seti üzerinden Cilt Kanseri Tespiti. Black Sea Journal of Engineering and Science, 4(4), ss. 192-200. <https://doi.org/10.34248/bsengineering.938520>
- Hassan, M. u. (2018, 20 Kasım). VGG16 – Convolutional Network for Classification and Detection. Neurohive. <https://neurohive.io/en/popular-networks/vgg16/>
- JingpengZhai, WeiranShen, Singh, I., TomWanyama, & Gao, Z. (2020). A Review of the Evolution of Deep Learning Architectures and Comparison of their Performances for Histopathologic Cancer Detection. Procedia Manufacturing, 46, ss. 683-689. <https://doi.org/10.1016/j.promfg.2020.03.097>
- Jones, B., Dean, N., Wunderink, R., & Sockrider, M. (2016). What is Pneumonia? American Journal of Respiratory and Critical Care Medicine, 193(1). <https://doi.org/10.1164/rccm.1931P1>
- Kaushik, A. (2019). Understanding the VGG19 Architecture. Opengenius IQ. <https://iq.opengenius.org/vgg19-architecture/>
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). ImageNet classification with deep convolutional neural networks. Communications of the ACM, 60(6), ss. 84-90. <https://doi.org/10.1145/3065386>
- Militante, S. V., Dionisio, N. V., & Sibbaluca, B. G. (2020, 8-8 Aug. 2020). Pneumonia Detection through Adaptive Deep Learning Models of Convolutional Neural Networks. 2020 11th IEEE Control and System Graduate Research Colloquium (ICSGRC), <https://doi.org/10.1109/ICSGRC49013.2020.9232613>
- Mooney, P. (2017). Chest X-Ray Images (Pneumonia). <https://www.kaggle.com/paultimothymooney/chest-x-ray-pneumonia>
- Ng, A., Ngiam, J., Foo, C. Y., Mai, Y., Suen, C., Coates, A., Maas, A., Hannun, A., Huval, B., Wang, T., & Tandon, S. (t.y.). Convolutional Neural Network. Stanford University. <http://deeplearning.stanford.edu/tutorial/supervised/ConvolutionalNeuralNetwork/>
- Rajpurkar, P., Irvin, J., Zhu, K., Yang, B., Mehta, H., Duan, T., Ding, D., Bagul, A., Langlotz, C., & Shpanskaya, K. (2017). CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. ArXiv, 1711.05225.
- Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017). ChestX-Ray8: Hospital-Scale Chest X-Ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), <https://doi.org/10.1109/CVPR.2017.369>
- World Health Organization Pneumonia Vaccine Trial Investigators' Group. (2001). Standardization of interpretation of chest radiographs for the diagnosis of pneumonia in children. <https://apps.who.int/iris/handle/10665/66956>
- Yang, Q., Zhang, Y., Dai, W., & Pan, S. J. (2020). Transfer Learning. Cambridge University Press. <https://doi.org/10.1017/9781139061773>
- Yılmaz, A. (2020). Yapay Zekâ. Kodlab Yayınları. <https://books.google.com.tr/books?id=JsoqEAAAQBAJ>